



Instituto Tecnológico de Buenos Aires (ITBA)

16.30 – Proyecto Final de Carrera
Bioingeniería

**Diseño y desarrollo de un calzado
instrumentado para la detección de
anomalías de la marcha mediante
aprendizaje automático en el borde y
biofeedback háptico personalizado**

Autores: Azcueta Busco, Tobías – 63362
Gramaglia, Juan Bautista – 63389

Docentes: Carbone, Corti, Espósito, Tajerian

Año: 1^{er} Cuatrimestre, 2026

1. Resumen del Proyecto

El presente proyecto aborda el riesgo de caídas en pacientes con secuelas de Accidente Cerebrovascular (ACV). El objetivo es desarrollar un ecosistema tecnológico integrado compuesto por un calzado instrumentado (zapatillalla inteligente bilateral), una aplicación de escritorio de ejecución en tiempo real con un *backend* de entrenamiento personalizado.

El sistema utiliza sensores inerciales (IMU) y sensores de fuerza resistiva (FSR) para capturar la dinámica de la marcha con precisión clínica fuera del laboratorio. La innovación radica en algoritmos de aprendizaje automático de tipo *one-class* que identifican anomalías a partir de un patrón basal personalizado, generado dinámicamente desde la propia marcha del paciente. La inferencia se ejecuta íntegramente en el borde (*Edge AI*), lo que habilita una corrección vibrotáctil en tiempo real. El valor del proyecto reside en la transición del monitoreo desde entornos hospitalarios fijos hacia un sistema de uso cotidiano, con una intervención personalizada de baja latencia.

2. Introducción

El Accidente Cerebrovascular (ACV) es la tercera causa de muerte y la segunda causa de discapacidad permanente en adultos a escala global [1]. Aproximadamente el 80 % de los sobrevivientes presenta hemiplejía por la pérdida del control central sobre el sistema motor, lo que deriva en un patrón de marcha hemipléjico característico [3]. El deterioro de la marcha es uno de los factores que más afecta la participación social, la autonomía y la calidad de vida del paciente, por lo que su rehabilitación es un aspecto crucial del manejo post-ACV.

Las caídas constituyen el problema clínico más crítico asociado a esta marcha: cada caída incrementa el riesgo de fractura, hospitalización y dependencia. La intervención preventiva sobre el riesgo de caída tiene, por lo tanto, un valor clínico desproporcionadamente alto frente a su costo. Existe evidencia de que parámetros cuantitativos como la asimetría de carga interextremidad y la velocidad de oscilación postural permiten predecir el riesgo de caída post-ACV [2].

La rehabilitación tradicional, realizada en clínicas con sesiones supervisadas, presenta tres limitaciones estructurales: cobertura temporal acotada a unas pocas horas semanales, evaluación subjetiva dependiente del observador, y la carga logística que implica el traslado frecuente para pacientes con dificultad para moverse [3]. La marcha en condiciones reales del hogar puede diferir sustancialmente de la observada en el laboratorio.

Los dispositivos *wearable* han emergido como la categoría disruptiva: portables, asequibles y capaces de recolectar datos en condiciones de vida real con monitoreo continuo. La evidencia demuestra que las plantillas inteligentes con sensores IMU permiten medir parámetros espacio-temporales de marcha con coeficientes de correlación intraclase (ICC) superiores a 0,90 respecto al *gold standard* de captura óptica de movimiento [5], y que un sistema de biofeedback vibrotáctil integrado en el calzado mejora de forma inmediata el patrón de marcha hemipléjico [4].

Sin embargo, persiste una brecha tecnológica. Los modelos genéricos de inteligencia

artificial entrenados sobre poblaciones presentan una performance próxima al azar en esta población debido a la alta heterogeneidad de los patrones motores, mientras que los modelos personalizados por sujeto alcanzan exactitudes superiores al 97 % [9]. Esto justifica un sistema capaz de construir un patrón basal personalizado (*ground truth*) para cada paciente. El presente proyecto propone cerrar esa brecha mediante una plantilla inteligente bilateral que detecta desviaciones respecto a una línea de base individual y activa en tiempo real un actuador vibrotáctil para corregir la marcha

3. Justificación

El ACV es la principal causa de discapacidad motora a largo plazo. La marcha hemipléjica que lo acompaña presenta alteraciones biomecánicas bien documentada déficit de propulsión, inversión excesiva del pie afectado y mayor variabilidad zancada a zancada [5] que funcionan además como predictores cuantificables del riesgo de caída [2]. Como la rehabilitación clínica carece de herramientas para evaluar al paciente fuera de la sesión supervisada, un dispositivo de uso domiciliario con monitoreo continuo y alerta temprana representa un salto cualitativo en la cobertura del seguimiento. El avance en sensores MEMS (MicroElectroMechanical Systems) de bajo consumo y el *Edge AI* permiten hoy ejecutar esta inferencia directamente en el dispositivo, habilitando un biofeedback en tiempo real.

Frente al estado del arte, la contribución original del proyecto reside en integrar, en un único dispositivo autónomo y de bajo costo, cuatro elementos que rara vez aparecen juntos: sensado bilateral FSR + IMU, detección de anomalías *one class* con patrón basal personalizado y adaptativo, inferencia en el borde y biofeedback vibrotáctil cerrado. Los sistemas de biofeedback validados en ACV usan lógica de umbral simple sin detección de anomalías [3], los sistemas con detección adaptativa no incorporan plantilla ni biofeedback [7], y las arquitecturas *Edge AI* más sofisticadas no tienen foco en ACV [8].

El trabajo se inscribe de lleno en el perfil de la Bioingeniería al integrar el conocimiento clínico-biomecánico de la marcha, la ingeniería electrónica del *wearable* y el procesamiento de señales con aprendizaje automático, en un prototipo funcional validable y con potencial de transferencia clínica.

4. Marco Teórico

El marco teórico se organiza en tres ejes que sustentan las decisiones metodológicas del proyecto: el contexto clínico de la marcha hemipléjica, los sensores de medición y extracción de características, y la detección personalizada de anomalías con biofeedback en el borde. Se desarrollan únicamente los conceptos con correlato directo en la metodología propuesta.

4.1. Marcha hemipléjica post-ACV

La marcha post ACV presenta un conjunto consistente de alteraciones. El lado parético utiliza predominantemente las regiones laterales del pie y es incapaz de activar las anteromediales, lo que reduce drásticamente la propulsión (*push-off*); además, el pie afectado se invierte en exceso, reduciendo el área de contacto medial y desestabilizando el

balance en *mid-stance* [5][3]. La asimetría interextremidad se confirma en prácticamente todas las variables de marcha excepto en el tiempo total de zancada, que tiende a igualarse por la sincronía del ciclo [5]; esto indica qué métricas conviene comparar bilateralmente. La variabilidad zancada a zancada medida como coeficiente de variación del tiempo de *stance* es uno de los rasgos más discriminativos para distinguir marcha post-ACV de marcha sana [1].

4.2. Sensórica FSR + IMU y extracción de características

El sistema combina dos sensores complementarios por pie. Los sensores de fuerza resistiva (FSR) son resistencias poliméricas cuya resistencia decrece al comprimirse; con 3 o 4 unidades en talón y antepié (medial y lateral) se cubren los marcadores patológicos esenciales déficit de propulsión e inversión medial-lateral del pie. Las unidades de medición inercial (IMU) integran acelerómetro y giróscopo triaxiales (6-DOF) y miden la cinemática del pie en vuelo. La complementariedad es estructural: el FSR mide la interfaz pie-piso (cuándo y cómo se establece el contacto, robusto al *drift*) mientras el IMU mide la cinemática del *swing*, y su fusión permite detectar de forma robusta los eventos de marcha (*heel-strike* y *toe-off*). Esta combinación ha sido aplicada específicamente a la evaluación de marcha hemipléjica correlacionándola con escalas clínicas reconocidas [9].

Sobre las señales se extraen características (*features*) en lugar de alimentar las señales crudas al clasificador, lo que reduce la dimensionalidad y aporta interpretabilidad clínica. El núcleo es un conjunto de parámetros espacio-temporales velocidad, cadencia, longitud y tiempo de zancada, tiempo de *stance* [4]. La evidencia más robusta en ACV [1] (N = 85 pacientes y 97 controles) demostró que apenas tres características alcanzan un 90 % de exactitud y nueve la elevan al 96,7 %, lo que indica que el problema es de baja dimensionalidad y favorece su implementación embebida. El proyecto adopta una estrategia progresiva: un vector mínimo espacio-temporal y de variabilidad, ampliado luego con características de presión plantar y de simetría interextremidad específicas de ACV.

4.3. Detección de anomalías personalizada y biofeedback en el borde

La detección se formaliza como un problema *one-class* (*novelty detection*): a partir de zancadas de marcha normal del propio paciente, recolectadas en una calibración inicial, se construye un modelo de normalidad personalizado que alerta cuando una nueva zancada se desvía de él. Esta formulación es preferible a la clasificación binaria supervisada porque las anomalías son raras e impredecibles y porque la variabilidad inter-individual hace fracasar a los modelos genéricos: un modelo global alcanzó solo un 55 % de exactitud, frente a un 97,7 % de uno personalizado y un AUC de 0,967 de un clasificador *one-class* entrenado con marcha normal del propio sujeto [6].

Los algoritmos candidatos, ordenados por complejidad creciente, son cuatro: distancia de Mahalanobis multivariada, Isolation Forest, autoencoder denso y, como techo de complejidad, un autoencoder LSTM [7]. Los cuatro admiten adaptación online con distinta granularidad: Mahalanobis se actualiza zancada a zancada con costo despreciable; Isolation Forest se reentrena periódicamente sobre las zancadas recientes acumuladas;

los autoencoders se reentrenan en hardware vinculado al sistema (smartphone o PC) y se despliegan al Pico con pesos cuantizados a int8 para reducir footprint y acelerar inferencia. Las dos variantes de autoencoder se diferencian en su entrada: el denso opera sobre el vector de features extraídas por zancada, mientras que el LSTM opera sobre la señal cruda del ciclo y aprende sus propias representaciones temporales, a costa de mayor footprint y latencia. La adaptación continua es particularmente crítica en ACV, donde la recuperación funcional progresiva genera drift natural del patrón motor en semanas o meses [7]. La evaluación comparativa de los cuatro algoritmos en exactitud, latencia y uso de memoria constituye uno de los objetivos experimentales del proyecto.

La inferencia se ejecuta íntegramente en el dispositivo (*Edge AI*) para evitar la latencia de la nube, funcionar sin conectividad y preservar la privacidad de datos sensibles [8]. El biofeedback devuelve al usuario, en tiempo real, información que no percibe por sí mismo; la modalidad vibrotáctil es apropiada porque no satura la visión ni la audición, es discreta y tiene inmediatez sobre el sitio del problema. Existe evidencia clínica directa de su efectividad: un sistema vibrotáctil por umbral redujo la inversión del pie afectado y produjo un efecto de reequilibrio bilateral en pacientes con ACV [3]. El feedback debe ser escaso en frecuencia, ya que el continuo impone una carga cognitiva detectable en adultos mayores [10]; por ello el diseño contempla activación selectiva y patrones calibrables por paciente.

5. Objetivos

5.1. Objetivo General

Diseño y desarrollo de una zapatilla inteligente para la captura (*MoCap*) y caracterización del patrón de marcha, mediante la experimentación con algoritmos de detección de anomalías basados en la comparación dinámica de desviaciones respecto a un patrón de referencia adaptativo.

5.2. Objetivos de Mínima

1. Desarrollar un dispositivo *wearable* integrado en el calzado, capaz de medir variables relevantes de la marcha (aceleración, orientación del pie y eventos de contacto/apoyo) y transmitir los datos hacia una computadora cercana para su posterior análisis.
2. Diseñar un protocolo de calibración validado mediante estándares clínicos para la obtención de un patrón basal certificado (*ground truth*) que fundamente la personalización científica de los algoritmos de detección.
3. Implementar el software necesario para recibir, almacenar y procesar los datos provenientes del calzado durante las sesiones experimentales, de manera que sirvan de soporte a las distintas instancias de experimentación.
4. Diseñar y llevar adelante experimentos orientados a evaluar la capacidad del sistema desarrollado para detectar anomalías en el patrón de marcha, explorando para ello técnicas de extracción de características y de aprendizaje automático.

5.3. Objetivos de Máxima

1. Desarrollar un panel de visualización en el *backend* que permita al personal médico monitorear la evolución temporal de los parámetros de marcha del paciente y la frecuencia de las anomalías detectadas.
2. Optimizar el diseño del *wearable* mediante la integración total de sus componentes electrónicos, logrando una estética de producto finalizado y una ergonomía convencional que facilite su uso discreto.
3. Desarrollar un sistema de alerta mediante respuesta vibrotáctil en la zapatilla, accionado por órdenes desde el *backend* al momento en que el algoritmo detecte una marcha anómala.

6. Metodología (Preliminar)

El sistema se desarrollará siguiendo una arquitectura de tres capas:

Wearable

Integrará una unidad de medición inercial dual (IMU BMI270) bajo el arco del pie para capturar aceleración y orientación en tres ejes, junto con sensores de fuerza resistiva (FSR 400) en talón y metatarso para detectar los eventos de contacto y propulsión. Se implementará un firmware con inteligencia en el borde para segmentar los pasos localmente y transmitir los datos comprimidos vía Bluetooth/Wi-Fi.

Aplicación de escritorio (software de adquisición y análisis)

Funcionará como centro de recepción y procesamiento. Recibirá los datos del *wearable*, los almacenará y ejecutará el *pipeline* de extracción de características biomecánicas (tiempos de fase, entropía de la señal, amplitudes). Sobre estas características se entrenará y evaluarán los modelos de detección de anomalías.

Backend (entorno de I+D)

Utilizará Python como lenguaje principal para la extracción de variables características por paso y el re-entrenamiento periódico de los modelos. Se explorarán algoritmos como *Autoencoders*, SST-AD, SVR y *Random Forest* para identificar desviaciones respecto al patrón basal adaptativo.

Validación


Se empleará un protocolo de testeo de caminata supervisada (por ejemplo, el *Timed 25-Foot Walk Test*) sincronizado con mediciones externas de referencia para verificar que los datos del *wearable* reflejen la condición clínica real del sujeto.

7. Planificación de Tareas

El proyecto se organiza en seis fases a lo largo del año 2026, desde el anteproyecto hasta la defensa de la tesina. El siguiente cuadro y el diagrama de Gantt resumen su distribución temporal.

A continuación se presenta el diagrama de Gantt correspondiente:

Fase	Descripción	Período (2026)
I	Anteproyecto y fundamentación.	Abr–may
II	Diseño y desarrollo del hardware (<i>wearable</i>).	May–jun
III	Desarrollo del software y ecosistema digital.	Jun–ago
IV	Integración circular y pruebas de sistema.	Ago
V	Testeo, validación y análisis de resultados.	Ago–sep
VI	Finalización (estadística, tesis y defensa).	Sep–nov



8. Costo (Preliminar)

Componente / Servicio	Descripción	Costo estimado (ARS)
IMU BMI270	Sensor inercial de ultra bajo consumo	5000\$ [x2]
FSR 400 ×4	Sensores de fuerza resistiva (talón y metatarso)	40000\$ [x8]
Microcontrolador	Raspberry Pi pico o similar con Bluetooth/Wi-Fi	15000\$ [x3]
Motores de vibración	Actuadores para biofeedback háptico	2000\$ [x10]
Batería Li-Po	Fuente de energía recargable (3.7 V)	15000\$ [x3]
Zapatilla base	Calzado convencional para modificación	80000\$ [x1]
Total estimado		\$ [520000]

Cuadro 1: Estimación preliminar de costos. ML = precio según Mercado Libre al momento de la compra.

9. Referencias Bibliográficas (Preliminar)

- [1] P. Brasiliano *et al.*, “Identifying key gait features in stroke patients using wearable inertial sensors and supervised and unsupervised machine learning,” *Scientific Reports*, vol. 16, art. 8908, 2026, doi: 10.1038/s41598-026-43666-7.
- [2] S. H. Jung *et al.*, “Prediction of post-stroke falls by quantitative assessment of balance,” *Annals of Rehabilitation Medicine*, vol. 41, no. 3, pp. 339–346, 2017, doi: 10.5535/arm.2017.41.3.339.
- [3] C. Z.-H. Ma, Y.-P. Zheng, and W.-C. C. Lee, “Changes in gait and plantar foot loading upon using vibrotactile wearable biofeedback system in patients with stroke,” *Topics in Stroke Rehabilitation*, vol. 25, no. 1, pp. 20–27, 2018, doi: 10.1080/10749357.2017.1380339.

- [4] L. Riglet *et al.*, “The use of embedded IMU insoles to assess gait parameters: a validation and test-retest reliability study,” *Sensors*, vol. 23, no. 19, art. 8155, 2023, doi: 10.3390/s23198155.
- [5] D. Kang, “The analysis of gait variables and plantar pressure patterns in community-dwelling elderly patients with hemiplegic stroke,” *Journal of Musculoskeletal Science and Technology*, vol. 9, no. 1, pp. 25–35, 2025, doi: 10.29273/jmst.2025.9.1.25.
- [6] Toth *et al.*, “Bioinformatics-inspired IMU stride sequence modeling for fatigue detection using spectral-entropy features and hybrid AI in performance sports,” *Sensors*, 2025, PMC12845696.
- [7] M.-C. Lee, J.-C. Lin, and S. Katsikas, “GAD: a real-time gait anomaly detection system with online adaptive learning,” arXiv:2405.09561, 2024.
- [8] A. M. Kirubakaran *et al.*, “Real-time anomaly detection on wearables using edge AI,” *International Journal of Engineering Research and Technology*, vol. 14, no. 11, 2025, doi: 10.5281/zenodo.18074824.
- [9] Z. Pan, H. Gao, Y. Chen, Z. Xie, and L. Xie, “Evaluation of hemiplegic gait based on plantar pressure and inertial sensors,” *IEEE Sensors Journal*, vol. 23, no. 11, pp. 12008–12017, 2023, doi: 10.1109/JSEN.2023.3268669.
- [10] H. Iwata *et al.*, “Using a vibrotactile biofeedback device to augment foot pressure during walking in healthy older adults: a brief report,” *Frontiers in Psychology*, vol. 10, art. 1008, 2019, doi: 10.3389/fpsyg.2019.01008.

10. Lugar de Realización

Laboratorio de Ciencias de la Vida/ Sala de Captura de Movimiento – ITBA, Sede Distrito Tecnológico.

11. Tutores

Tutor: Ramele, Rodrigo - rramele@itba.edu.ar

Cotutor: Tasos Papastylianou - tasos.papastylianou@essex.ac.uk